



Vortrag im Rahmen des Astrophysikalischen Seminars:

Bayessche Datenanalyse in der Astronomie

Milena Oehlers

06. Juli 2021

Bayessche Datenanalyse in der Astronomie

- Einführung & Motivation am linearen Beispiel
- Grundlagen der Bayesschen Theorie
- Wahl des Priors
- Markov Chain Monte Carlo (MCMC)
 - Mathematische Grundlagen
 - Numerische Methoden: (Adaptive) Metropolis Hastings
 - Konvergenzbestimmung
- Anwendung: Lineares Beispiel; Binäres System aus Stern und Exoplanet
- Zusammenfassung

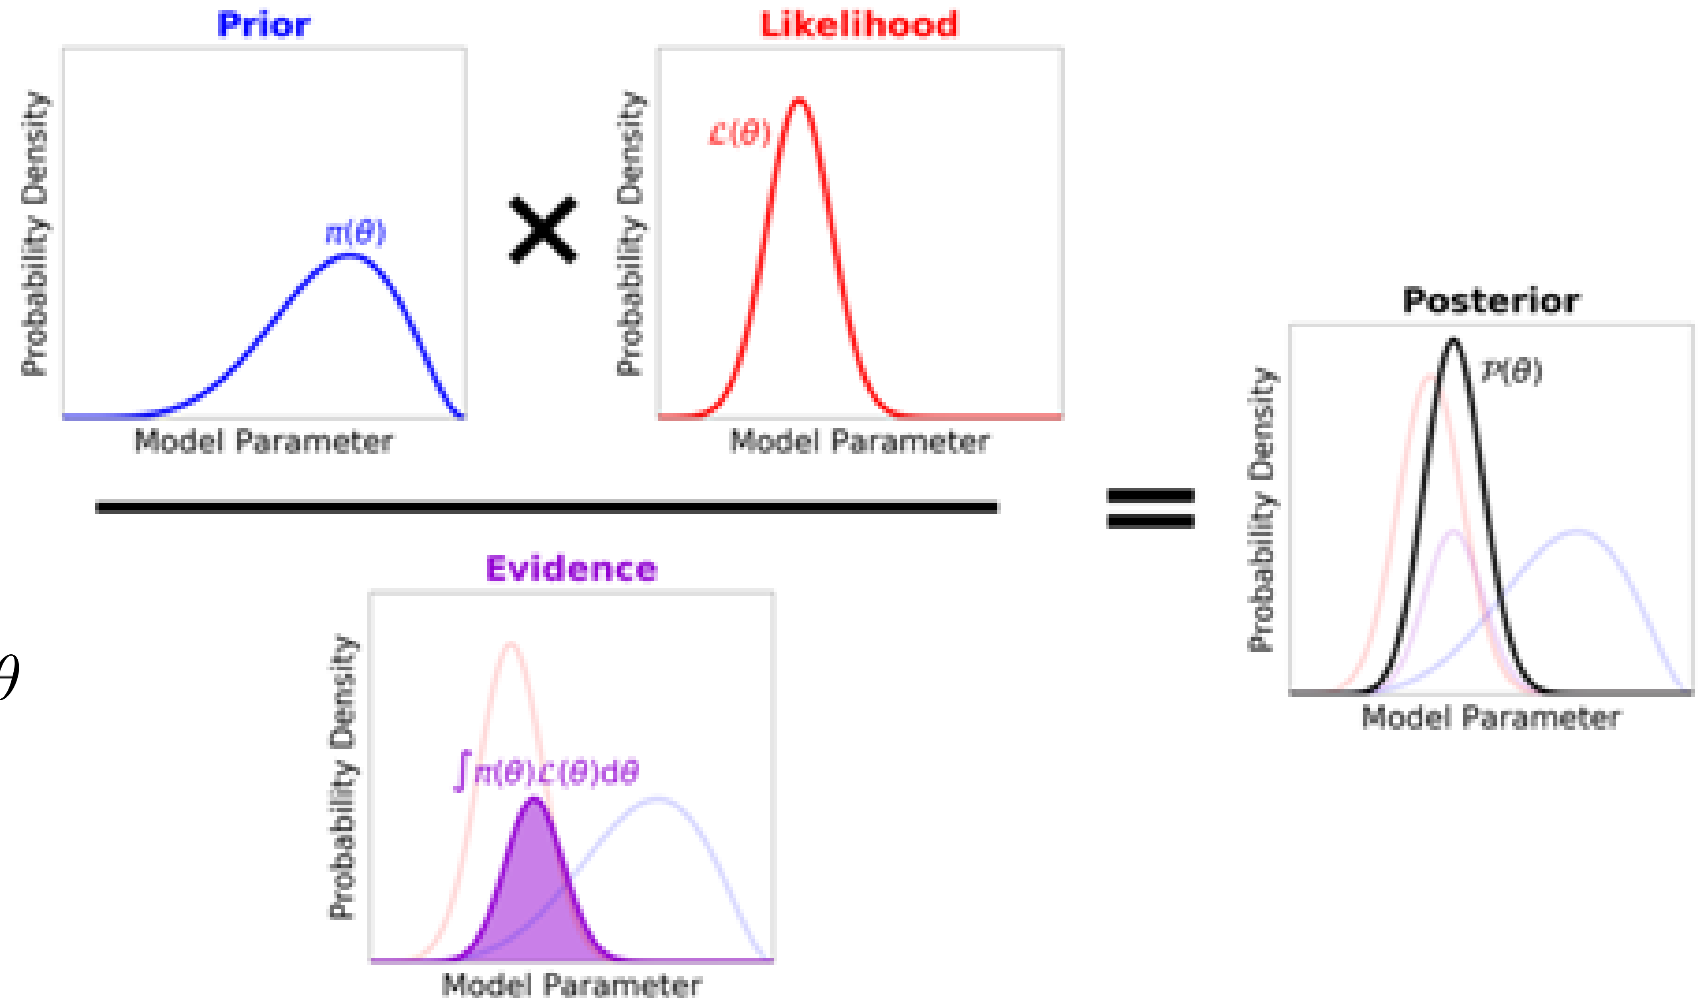
Idee der Bayesschen Theorie

Bekannt:

- Daten
- Modell
- Zusatzinfo

Gesucht:

Modellparameter θ



Motivation am linearen Beispiel

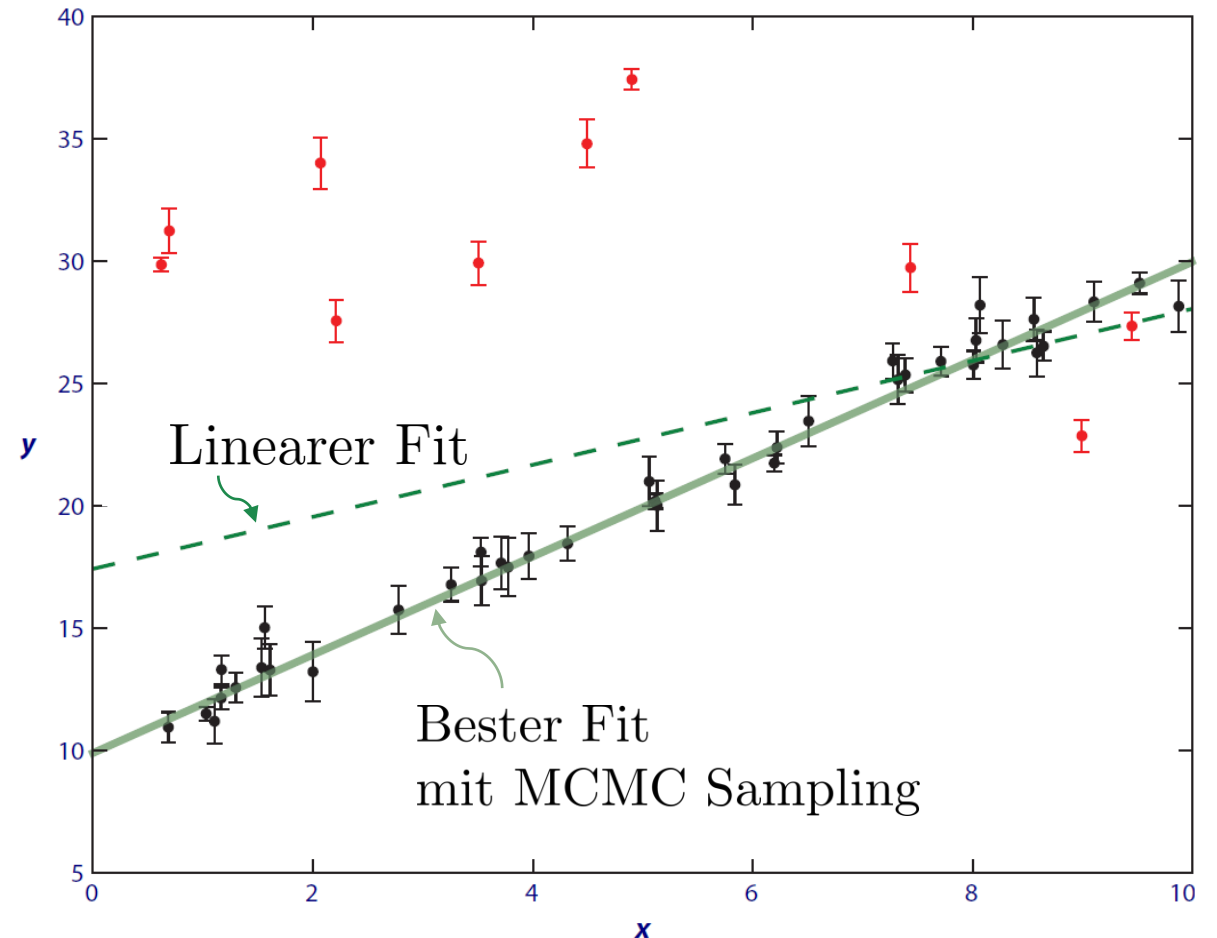
Bekannt:

- Datenpunkte $z_j = (x, y)_j$
- Messunsicherheit σ_z

Modellannahmen:

- Real: $y_j = m \cdot x_j + c$
- Ausreißer: $y_j \sim \mathcal{N}(\mu_a, \sigma_a)$

Ziel: Parameter m und c
ohne Ausreißer schätzen



Beispiel und Abbildung adaptiert aus [1]

Motivation am linearen Beispiel (adaptiert aus [1])

Modellannahmen \Rightarrow Wsk., Messpunkte $Z = \{z_1, \dots, z_N\}$ zu erhalten für gegebene Modellparameter $\theta = (m, c, \mu_a, \sigma_a, P_a)$:

$$p(Z|\theta, \sigma_z) = \prod_{j=1}^N [p(z_j|\mu_a, \sigma_a, \sigma_z)P_a + p(z_j|m, c, \sigma_z)(1 - P_a)]$$

mit
$$p(z_j|m, c, \sigma_z) = \frac{1}{\sqrt{2\pi}\sigma_z} \exp \left[-\frac{(y_j - mx_j - c)^2}{2\sigma_z^2} \right]$$

und
$$p(z_j|\mu_a, \sigma_a, \sigma_z) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(y_j - \mu_a)^2}{2\sigma^2} \right] \quad \text{mit} \quad \sigma^2 = \sigma_z^2 + \sigma_a^2$$

aber gesucht: $p(\theta|Z, \sigma_z)$, denn $\mathbb{E}(\theta) = \int \theta \cdot p(\theta|Z, \sigma_z) d\theta$
und $\sigma_\theta = \int (\theta - \mathbb{E}(\theta))^2 \cdot p(\theta|Z, \sigma_z) d\theta$

Grundlagen der Bayesschen Theorie

	θ_1	θ_2	...	Gesamt
Z_1	$p(Z_1, \theta_1)$	$p(Z_1, \theta_2)$...	$p(Z_1)$
Z_2	$p(Z_2, \theta_1)$	$p(Z_2, \theta_2)$...	$p(Z_2)$
...
Gesamt	$p(\theta_1)$	$p(\theta_2)$...	1.0

bekannte Information
hier: Messunsicherheit σ_z

Produktregel: $p(Z, \theta|I) = p(\theta|Z, I)p(Z|I) = p(Z|\theta, I)p(\theta|I)$

\Rightarrow Satz von Bayes: $p(\theta|Z, I) \propto p(Z|\theta, I) \cdot p(\theta|I)$

$\underbrace{\hspace{1cm}}_{\text{gesucht}}$
 $\text{Posterior} \propto$
 $\underbrace{\hspace{1cm}}_{\text{Modellannahmen}}$
 $\text{Likelihood} \cdot$
 $\underbrace{\hspace{1cm}}_{\text{zu w\u00e4hlen}}$
 Prior

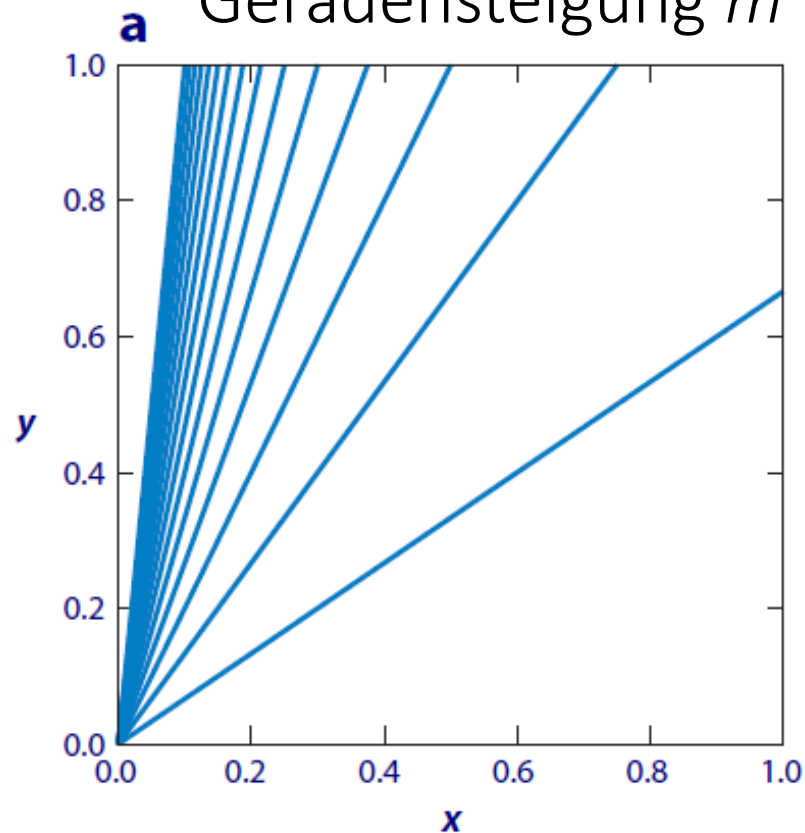
Wahl des Priors $p(\theta|I)$ (adaptiert aus [1])

- Informativer Prior: kann durch Info aus vergangenen Analysen sehr restriktiv gewählt werden, wichtig bei nicht aussagekräftigen Daten
- Ignorance Prior: bei aussagekräftigen Daten reicht glatter Prior in Bereichen hoher Parameter-Likelihood für gute Ergebnisse, z.B. durch
 - Gleichverteilung in möglichem Parameterraum
 - Invarianz der Likelihood $p(x'|\theta')dx' = p(x|\theta)dx$ bezüglich Transformationsgruppen $(\theta', x') = h(\theta, x)$ wie Translation, Skalierung, Rotation...
 - Maximierung der Entropie $S = - \sum_i p_i \log p_i$ von Priors, die Einschränkungen erfüllen

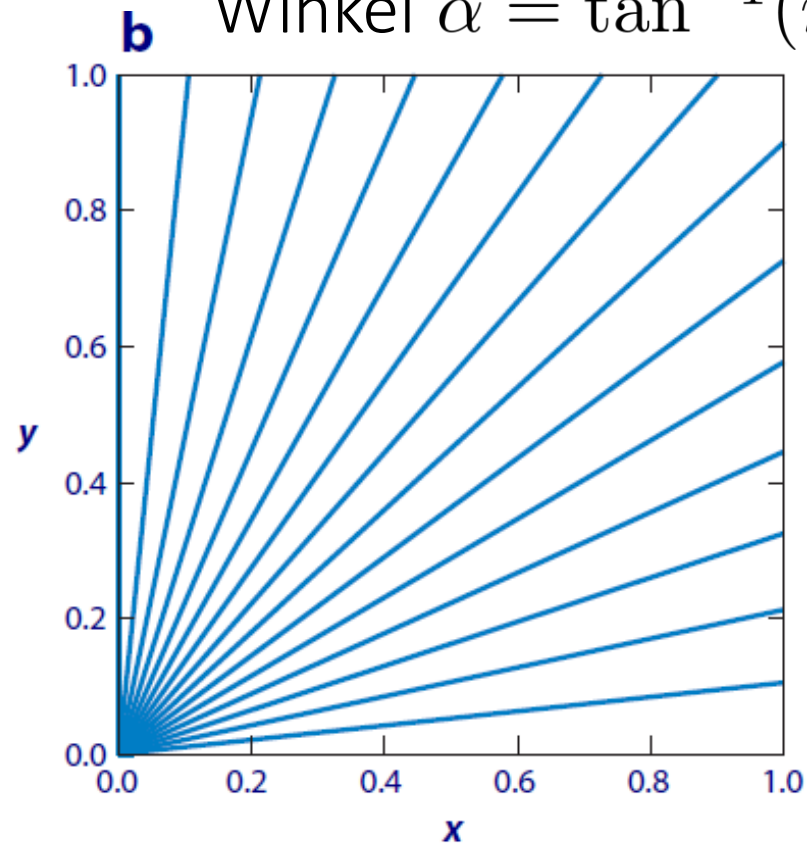
Motivation am linearen Beispiel (adaptiert aus [1])

Nutze Rotationsinvarianz, um Verzerrungen des Priors zu vermeiden:

Gleichverteilt in
Geradensteigung m



Gleichverteilt in
Winkel $\alpha = \tan^{-1}(m)$



Markov Chain Monte Carlo (MCMC) [1]

Ziel: $\mathbb{E}(\theta) = \int \theta \cdot p(\theta|Z, \sigma_z) d\theta$ und $\sigma_\theta = \int (\theta - \mathbb{E}(\theta))^2 \cdot p(\theta|Z, \sigma_z) d\theta$

Integrale meist nicht analytisch lösbar. MCMC zieht stattdessen iterativ Stichproben θ_i mithilfe einer Markovkette, deren Gleichgewichtsverteilung $p^*(\theta) = p(\theta|Z, \sigma_z)$ ist

Für Markovkette mit Übergangswsk. $K(\theta_i, \theta_{i+1}) = p(\theta_{i+1}|\theta_i)$

\exists stationäre Wsk.verteilung $p^* \Leftarrow p^*(\theta_i)K(\theta_i, \theta_{i+1}) = p^*(\theta_{i+1})K(\theta_{i+1}, \theta_i)$

$\left. \begin{array}{l} \text{stationär} \\ \& \text{irreduzibel} \end{array} \right\} \Rightarrow \left\{ \begin{array}{l} p^* \text{ ist eindeutig} \\ \& \text{positiv rekurrent} \\ \text{aperiodisch} \end{array} \right\}$

\curvearrowright Detailed Balance Bedingung

$$\Rightarrow \lim_{i \rightarrow \infty} \|pK^i - p^*\| = 0$$

Monte Carlo Integration: $\mathbb{E}_{p^*}[g(\theta)] = \int g(\theta) p^*(\theta) d\theta = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n g(\theta_i)$

MCMC-Methoden: Metropolis-Hastings (MH) [1]

Setze Übergangswahrscheinlichkeit $K(\theta_i, \theta_{i+1}) = q(\theta_{i+1}|\theta_i)\alpha(\theta_i, \theta_{i+1})$
mit Akzeptanzwahrscheinlichkeit

$$\alpha(\theta_i, \theta_{i+1}) = \min[1, a_i] \quad \text{mit} \quad a_i = \frac{p^*(\theta_{i+1})q(\theta_i|\theta_{i+1})}{p^*(\theta_i)q(\theta_{i+1}|\theta_i)}$$

um *Detailed Balance* zu erfüllen.

Setze Vorschlagsdichte $q(\theta_{i+1}|\theta_i)$

- *Symmetrisch* $= q(\theta_i|\theta_{i+1}) \Rightarrow a_i = p^*(\theta_{i+1})/p^*(\theta_i)$
- *Random Walk* $= q(\theta_{i+1} - \theta_i)$, z.B. $\mathcal{N}(\theta_{i+1}; \theta_i, \Sigma)$
- ...

$$\Sigma^* \stackrel{[2]}{=} (2.38^2/D)\Sigma_{p^*}$$

nicht
Bekannt!

MCMC-Methoden: Adaptive (RW) Metropolis

Gewählt: Vorschlagsdichte $q(\theta_{i+1}|\theta_i) = \mathcal{N}(\theta_{i+1}; \theta_i, s_i \Sigma_i)$

Nach jedem Schritt i werden zusätzlich die Vorschlagsdichteparameter $\rho_i = (s_i, \mu_i, \Sigma_i)$ aktualisiert, sodass $\rho_i \xrightarrow{i \rightarrow \infty} \rho^*$, für welche die Markovkette am schnellsten konvergiert:

Setze:

$\log s_{i+1} - \log s_i = \gamma_{i+1}(\alpha_i - \alpha^*)$ mit $\alpha^* = \alpha(D)$ bekannt

und $\Sigma_{i+1} - \Sigma_i = \gamma_{i+1}[(\theta_{i+1} - \mu_i)(\theta_{i+1} - \mu_i)^T - \Sigma_i]$

mit $\mu_{i+1} - \mu_i = \gamma_{i+1}(\theta_{i+1} - \mu_i)$

Wobei: $\sum_{i=1}^{\infty} \gamma_i = \infty$ und $\sum_{i=1}^{\infty} \gamma_i^2 < \infty$

z.B.: $\gamma_i = \gamma/i^\beta$
mit $\beta \in]0, 1[$

MCMC Konvergenzbestimmung [1]

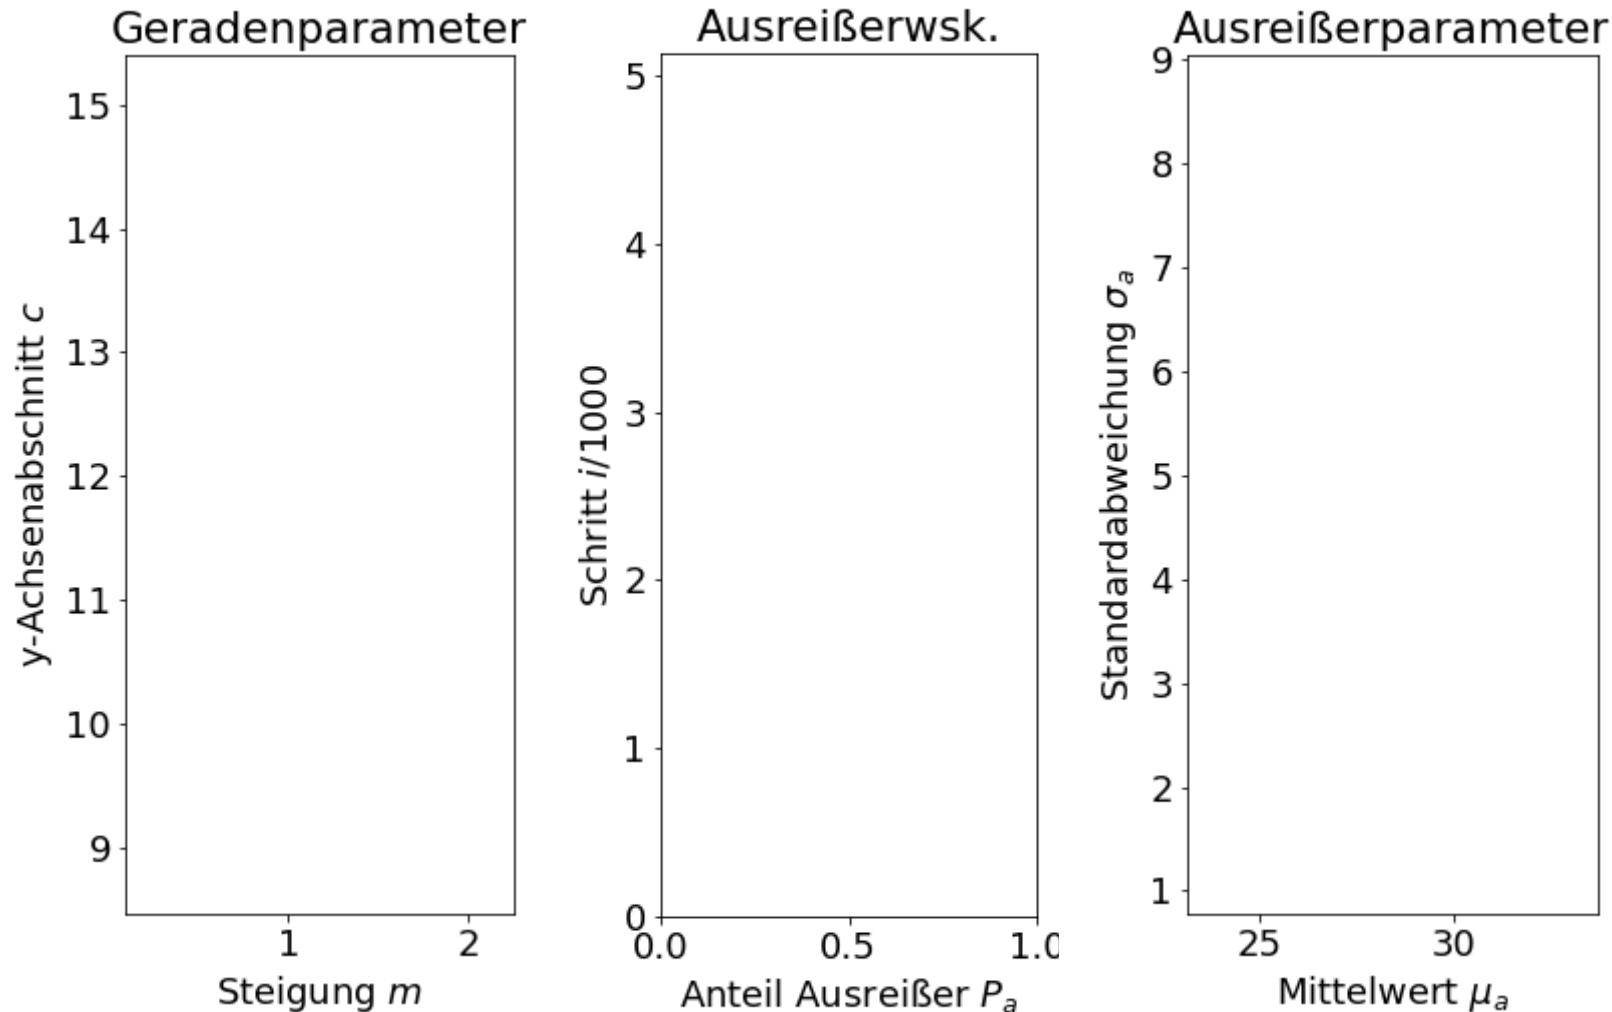
Zwischenkettenvarianz: Berechne K Markovketten $k = 1, \dots, K$ gleichzeitig, welche $p^*(\theta)$ aus den Ziehungen der letzten S Schritte ableiten.

- Jede Kette hat eine innere Varianz $I_k = \frac{1}{S-1} \sum_{s=1}^S (\theta_{s,k} - \bar{\theta}_k)^2$,
 \Rightarrow durchschnittliche Innerkettenvarianz $I = \frac{1}{K} \sum_{k=1}^K I_k$
- Zwischenkettenvarianz $Z = \frac{1}{1-K} \sum_{k=1}^K (\bar{\theta}_k - \bar{\theta})^2$
- gepoolte Varianz $V = \frac{K+1}{K} Z + \frac{S-1}{S} I$

Wenn $Z \rightarrow 0$ geht Konvergenzratio $R = \sqrt{V/I} \rightarrow 1$

Motivation am linearen Beispiel

Adaptive RW Metropolis mit Konvergenzkriterium Zwischenkettenvarianz



Kette $k \in [1, \dots, 5]$,
Akzeptiere die letzten
1000 Modellparameter-
werte $\theta = (m, c, \mu_a, \sigma_a, P_a)$

- $\text{---} \times [\theta_{i-1000}, \theta_i]_k$
- $\text{---} \times KI_{0.95}[q_k(\theta_{i+1}|\theta_i)],$
- $\text{---} \times \bar{\theta}_k \text{ und } KI_{0.95}(\theta_k)$
- $\text{---} \times \bar{\theta} \text{ und } KI_{0.95}(\bar{\theta}_k)$

KI : Konfidenzintervall

Anwendungsbeispiel: [1]

Binäres System aus Stern und Exoplanet

Illustration adaptiert aus [3]

$$v(t) = \kappa [\cos(f + \omega) + e \cos(\omega)] + \overline{v_Z}$$

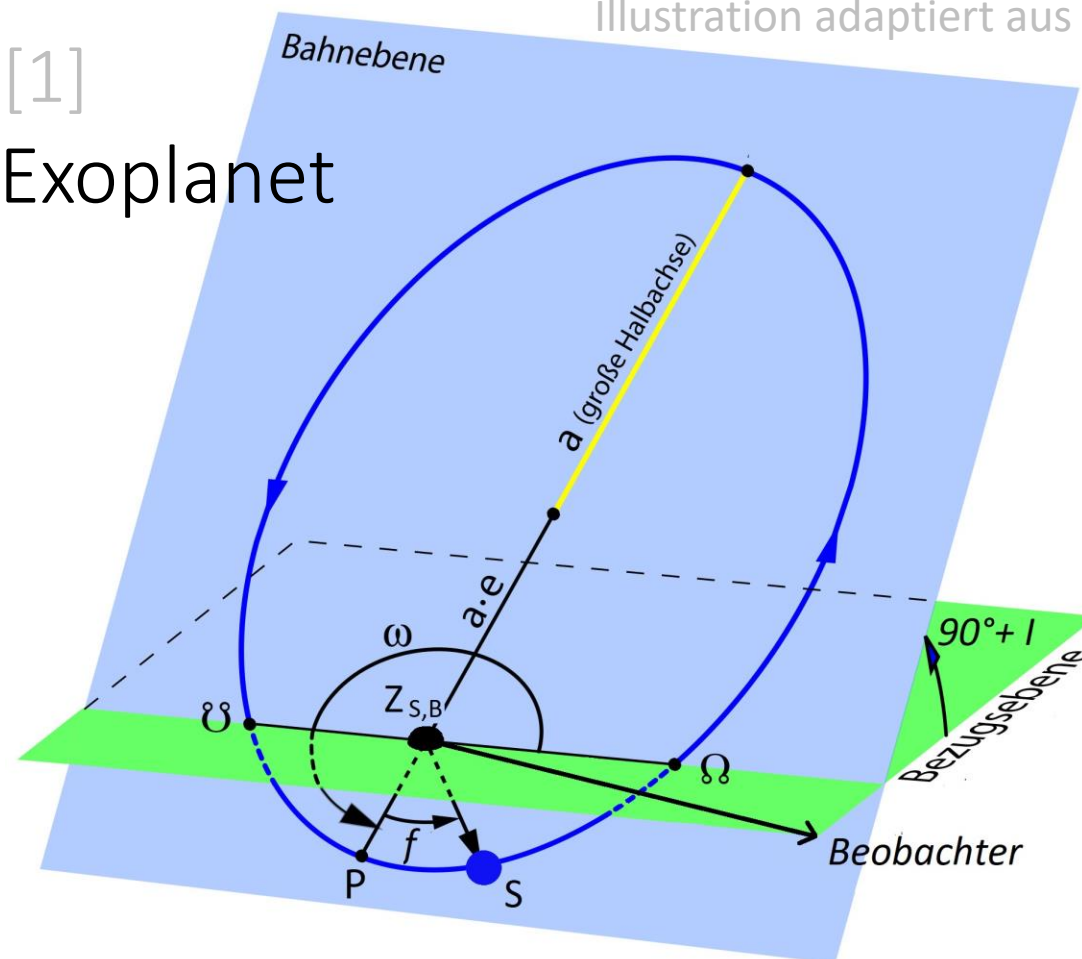
mit
$$\kappa = \frac{(2\pi G)^{1/3} m \sin(I)}{T^{1/3} (M + m)^{2/3} \sqrt{1 - e^2}}$$

$$\tan(f/2) = \sqrt{\frac{1+e}{1-e}} \tan(u/2)$$

$$u - e \sin(u) = \frac{2\pi}{T} (t - \tau)$$

$v(t)$	Radialgeschw. des Sterns S
M, m	Masse des Sterns/ Exoplaneten
I, e	Inklination/ Exzentrizität
f	wahre Anomalie

ω	Winkel von Perizentrum P zu aufsteigendem Knoten Ω
τ	Durchgangszeit durch P
T	Umlaufzeit



Anwendungsbeispiel: [1]

Binäres System aus Stern und Exoplanet

Gesucht: Modellparameter $\theta = (\overline{v_Z}, \kappa, T, e, \tau, \omega, S)$ mit Spektralvarianz S

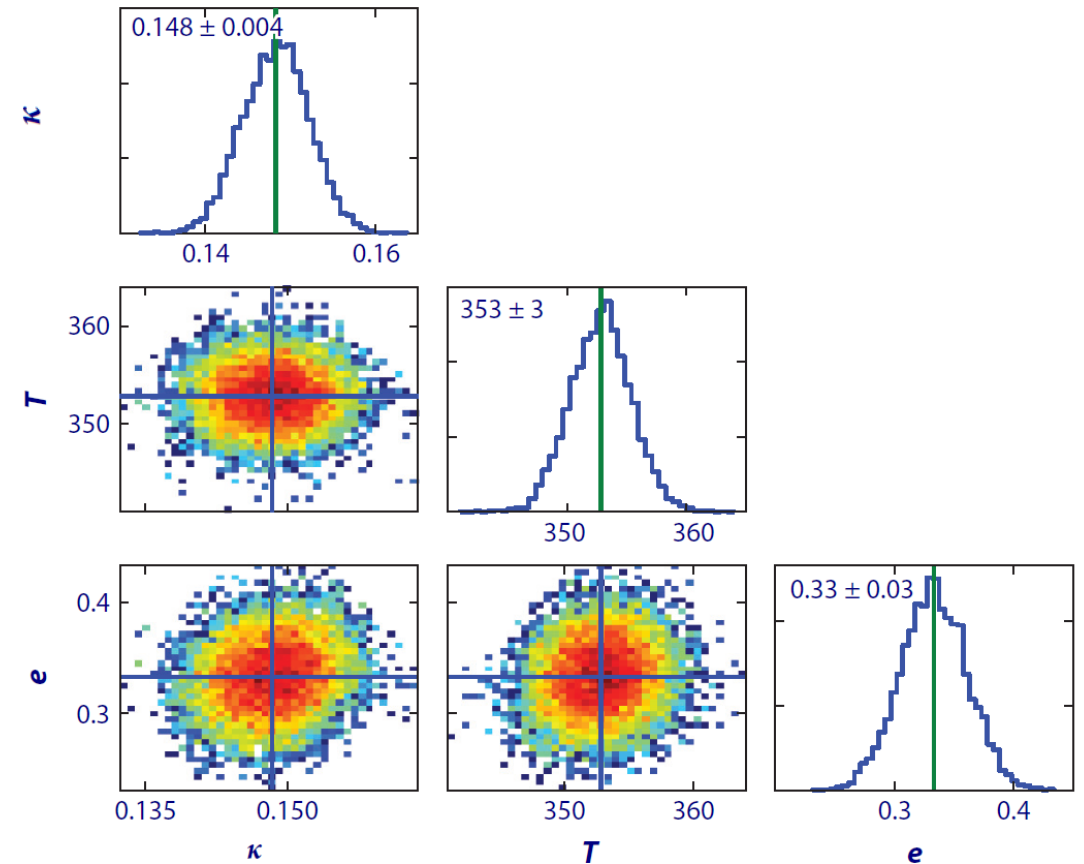
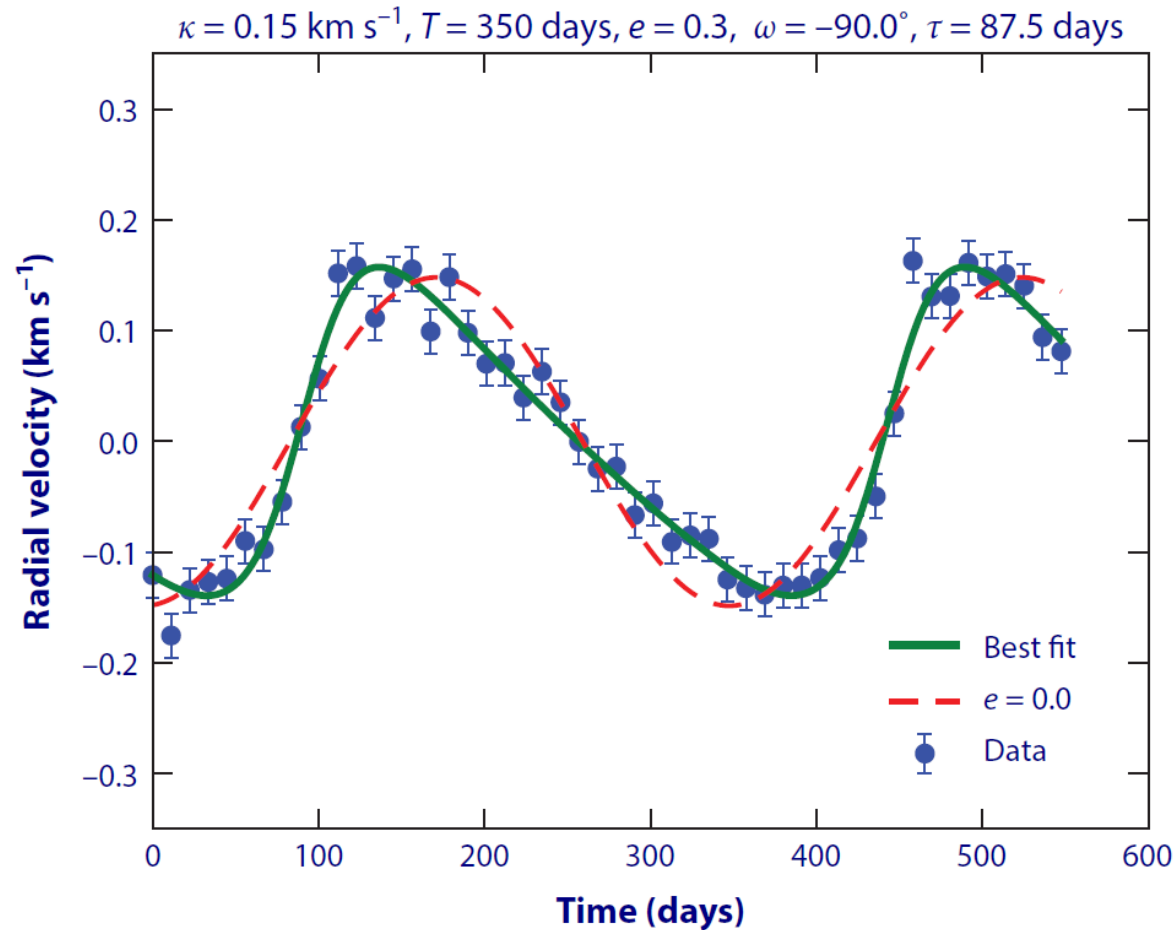
Bekannt:

- Datenpunkte $D = [d_i] = [(t, v)_i]$ mit $i = 1, \dots, M$
- Messunsicherheit σ_v

Aus Modell folgt Posterior:
$$p(\theta|D) \propto p(\theta) \prod_{i=1}^M \mathcal{N}(v_i | v(t_i; \theta), \sigma_v^2 + S^2)$$

Anwendungsbeispiel: [1]

Binäres System aus Stern und Exoplanet



Illustrationen aus [1]

Zusammenfassung

- Motivation am linearen Beispiel: Wie ohne Ausreißer Datenpunkte fitten?
- Grundlagen: Vierfeldertafel, Produktregel, Satz von Bayes
- Wahl des Priors: Ignorance Prior mit geringstem Bias durch Likelihood-Invarianz
- Markov Chain Monte Carlo (MCMC): Methode zur Anwendung Bayesscher Datenanalyse
 - Mathematische Grundlagen: Markov Chain, Detailed Balance, Monte Carlo
 - Numerische Methoden: Adaptive Metropolis Hastings zur gleichzeitig iterativen Anpassung der Kovarianz der Vorschlagsdichte für schnelle Konvergenz der Markovkette
 - Konvergenzbestimmung mithilfe von Zwischenkettenvarianz $Z \rightarrow 0$ mehrerer gleichzeitig berechneter Markovketten, während durchschnittliche Innerkettenvarianz $I \rightarrow I^\infty > 0$
- Anwendung auf das lineare Beispiel: Illustration der fünf Markovketten, ihrer Vorschlagsdichten $q_k(\theta_{i+1}|\theta_i)$ und Innerkettenvarianzen I_k , sowie der Zwischenkettenvarianz Z
- Anwendung auf das binäre System aus Stern und Exoplanet für Fit der Radialgeschwindigkeit

Referenzen

- [1] Sharma, Sanjib. "Markov chain monte carlo methods for bayesian data analysis in astronomy." *Annual Review of Astronomy and Astrophysics* 55 (2017): 213-259.
- [2] Gelman, Andrew, Gareth O. Roberts, and Walter R. Gilks. "Efficient Metropolis jumping rules." *Bayesian statistics* 5.599-608 (1996): 42.
- [3] <https://de.wikipedia.org/wiki/Bahnneigung>

Backup-Folien

- Wahl des Priors (extended)
- MCMC-Methoden: Metropolis-Hastings (extended)
- MCMC-Methoden: Gibbs Sampling
- MCMC-Methoden: Adaptive (RW) Metropolis-Hastings (extended)
- Konvergenzbestimmung (extended)

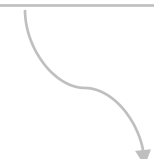
Wahl des Priors $p(\theta|I)$ (adaptiert aus [1])

- Suche in entarteten Parameterräumen durch Prior-Wahl einschränken
- Informativer Prior: kann durch Info aus vergangenen Analysen sehr restriktiv gewählt werden, wichtig bei nicht aussagekräftigen Daten
- Ignorance Prior: bei aussagekräftigen Daten reicht glatter Prior in Bereichen hoher Parameter-Likelihood für gute Ergebnisse, z.B. durch
 - Gleichverteilung in möglichem Parameterraum
 - Invarianz der Likelihood $p(x'|\theta')dx' = p(x|\theta)dx$ bezüglich Transformationsgruppen $(\theta', x') = h(\theta, x)$ wie Translation, Skalierung, Rotation...
 - Maximierung der Entropie $S = -\sum_i p_i \log p_i$ von Priors, die Einschränkungen erfüllen

MCMC-Methoden: Metropolis-Hastings (MH) [1]

Setze $K(\theta_i, \theta_{i+1}) = q(\theta_{i+1}|\theta_i)\alpha(\theta_i, \theta_{i+1})$ mit Akzeptanzwahrscheinlichkeit $\alpha(\theta_i, \theta_{i+1}) = \min[1, a_i]$ und $a_i = \frac{p^*(\theta_{i+1})q(\theta_i|\theta_{i+1})}{p^*(\theta_i)q(\theta_{i+1}|\theta_i)}$ um *Detailed Balance* zu erfüllen.

Setze Vorschlagsdichte $q(\theta_{i+1}|\theta_i)$

$$\Sigma^* \stackrel{[2]}{=} (2.38^2/D)\Sigma_{p^*}$$


- *Symmetrisch* $= q(\theta_i|\theta_{i+1}) \Rightarrow a_i = p^*(\theta_{i+1})/p^*(\theta_i)$
- *Random Walk* $= q(\theta_{i+1} - \theta_i)$, z.B. $U(\theta_i - \sigma, \theta_i + \sigma)$ oder $\mathcal{N}(\theta_i, \Sigma)$
- *Unabhängig* $= q(\theta_{i+1}) \hat{=} [p^*(\theta_{i+1}) \text{ mit längeren Ausläufern}]$
- *Langevin* $\sim \mathcal{N}(\theta_i + \frac{\sigma^2}{2} \nabla \log p^*(\theta_i), \sigma^2)$ falls $\nabla \log p^*(\theta_i)$ bekannt

MCMC-Methoden: Gibbs Sampling [1]

Bei jedem Schritt i , ziehe iterativ jeden Modellparameter $\theta_i^j = (m, c, \mu_a, \sigma_a, P_a)_i$ einzeln:

$$K(\theta_i, \theta_{i+1}) = \kappa_{1 \rightarrow d}(\theta_{i+1} | \theta_i) = \prod_{j=1}^d p^*(\theta_{i+1}^j | \theta_{i+1}^1, \dots, \theta_{i+1}^{j-1}, \theta_i^{j+1}, \dots, \theta_i^d)$$

$$\Rightarrow p^*(\theta_i) \kappa_{1 \rightarrow d}(\theta_{i+1} | \theta_i) = p^*(\theta_{i+1}) \kappa_{d \rightarrow 1}(\theta_i | \theta_{i+1}) \quad \text{Detailed Balance}$$

$$\Leftrightarrow \boxed{\int p^*(\theta_i) \kappa(\theta_{i+1} | \theta_i) d\theta_i = p^*(\theta_{i+1})} \quad \text{Def. von Stationarität}$$

Zufällige Parameterreihenfolge beim Ziehen \Rightarrow *Detailed Balance*

Falls Ziehen aus bedingter Dichte schwierig: *Metropolis Within Gibbs* für einzelne Parameter oder Parametersets

MCMC-Methoden: Adaptive (RW) Metropolis

Gewählt: Vorschlagsdichte $q(\theta_{i+1}|\theta_i) = \mathcal{N}(\theta_i, s_i \Sigma_i)$

Nach jedem Schritt i werden zusätzlich die Vorschlagsparameter

$\rho_i = (s_i, \mu_i, \Sigma_i)$ aktualisiert, sodass $\rho_i \xrightarrow{i \rightarrow \infty} \rho^*$, für welche

die Markovkette am schnellsten konvergiert:

Gesucht: $\langle N(\rho^*) \rangle = \hat{M}(\rho^*) = m^* = f(\theta^*) \xleftrightarrow{i \rightarrow \infty} f(\theta_i)$

z.B.: $\gamma_i = \gamma/i^\beta$
mit $\beta \in]0, 1[$

Setze $\rho_{i+1} - \rho_i = \gamma_i [f(\theta_{i+1}) - N(\rho_i)]$ mit $\sum_{i=1}^{\infty} \gamma_i = \infty$ und $\sum_{i=1}^{\infty} \gamma_i^2 < \infty$

$\Rightarrow \log s_{i+1} - \log s_i = \gamma_{i+1}(\alpha_i - \alpha^*)$ mit $\alpha^* = \alpha(D)$ bekannt

und $\Sigma_{i+1} - \Sigma_i = \gamma_{i+1}[(\theta_{i+1} - \mu_i)(\theta_{i+1} - \mu_i)^T - \Sigma_i]$

mit $\mu_{i+1} - \mu_i = \gamma_{i+1}(\theta_{i+1} - \mu_i)$

Konvergenzbestimmung [1]

- Effective Sample Size (ESS): Für N unabhängige Stichproben gilt $\sigma_{\theta}^{MC} = \sigma_{\theta} / \sqrt{N}$. Markovkette hat jedoch Autokorrelation

$$\rho_{\theta\theta}(t) = \frac{\mathbb{E}[(\theta_i - \bar{\theta})(\theta_{i+t} - \bar{\theta})]}{\mathbb{E}[(\theta_i - \bar{\theta})^2]} \neq 0$$

sodass $N \rightarrow N^{eff} = N / (2\tau_{int,\theta})$ mit $\tau_{int,\theta} = \frac{1}{2} \sum_{t=-\infty}^{\infty} \rho_{\theta\theta}(t)$

- Bei m gleichzeitig berechneten Ketten, welche $p^*(\theta)$ aus den letzten n Ziehungen ableiten, ergibt sich die gepoolte Varianz $V = \frac{m+1}{m} Z + \frac{n-1}{n} I$ mit Zwischen- und durchschnittlicher Innerkettenvarianz Z und I , sodass $R = \sqrt{V/I} \rightarrow 1$ Konvergenz anzeigt